小学校低学年向け英語会話 Bot「Mia」第 2 世代 (MIA2) の開発

語彙の調査、文脈長 1,024 の基礎学習、項目 (カード) 読解、計算とカードの振り分け、実機会話テスト、強化学習の試み

マーガレットリサーチ

記録: 秘書いずみ (Claude Sonnet 5.5)

2026 年 10 月 28 日

要旨

本報告は、自作の小型 LLM(約 4,000 万パラメータ) による英語会話 Bot「Mia」の第 2 世代 (MIA2、2026 年 10 月 23 日〜28 日) の開発をまとめたものである。第 1 世代の報告書 (2026 年 10 月 22 日) の後、(a) 日常会話の学習不足による不安定さ、(b) 計算とカード (知識) への切り替えが働かないこと、(c) カードが 1 行で情報が少ないこと、が課題として残った。MIA2 では、まず語彙と文脈長を調べ、基礎学習用の語彙は据え置き (読解にだけ出る語は後から足した)、文脈長を 256 から 1,024 に伸ばすことを決めた。基礎学習 (約 11.8 億トークン) をやり直し、Qwen で作った長い会話 (5.45 万会話) で会話 SFT を行った。知識は、題名と 200〜500 トークンの説明文を持つ**項目** (2,226 件、質問追加後で約 8.4 万問) に作り直した。項目の作り直しと質問の追加などの一連の改良で、50 項目 931 問の自動判定の読解正解率は 68% から 80% になった (1 行カードとの同一条件の比較はしていない)。計算とカードへの切り替えは、現行の Mia を微調整した**別モデルのルーター** (Plan B) が担当する。ルーターは文章題から式を取り出して電卓に渡し (計算の答え 0.976、ルーター v6、凍結テスト)、事実の質問には項目を検索して現行 Mia に読ませる (全体の正解率 70.4%、正しい項目を引けた率は下限つきで約 73%)。実機で見つかった弱点は、追加データでルーター v6 を作って直した。評価は、読解、会話、計算、カード、実機会話の 5 つの基準テストにまとめた。最後に、実機会話の質を強化学習 (GRPO 型、DeepSeek 採点の報酬) で上げようとしたが、2 回とも実機会話テストが誤差の範囲で、読解が低下したため採用しなかった。なお、評価は単一の乱数の種で、採点に LLM を使い、評価問題の一部は開発中の選択にも使っている。値には偏りを含む (第12節)。

1 はじめに

1.1 背景と課題

第 1 世代の Mia は、語彙を約 16,000 トークンに絞った自作モデルで、知識カード (1 行) を検索して読解モデルに読ませ、計算は電卓に任せる構想であった。その後の実機の会話で、オーナーが次の課題を挙げた。

1. 普通の会話はそこそこできるが、「あなたはどう?」と聞くと答えられなくなり、会話が不自然になる。TinyStories で学習しており、日常会話の学習が不足していると考えた。
2. 計算やカードへの切り替えがうまく働かない。「2+3」には答えるが、「鉛筆 2 本と鉛筆 3 本で何本」には切り替わらない。
3. 切り替えてもカードを見て「わからない」になることが多い。カードは 1 行なので、辞典のように数行にわたって書いた項目にしたほうがよいのではないか。
4. 語彙を増やすのは適当でないと考える。語彙の現状と学年の対応、会話で覚えておくべき長さ (トークン数) を確認したい。
5. 限られた語彙で会話例を大量に作る仕組みが必要である。費用がかかるので、Qwen(手元で動かす) で行う。

1.2 進め方

作業は次の順に行い、新しい作業はオーナーの承認を得てから始めた。成果がたまった時点で報告書を書き、作業記録 (MIA2.txt) にも追記した。

語彙・学年・文脈長の調査 → 長い会話データの生成 → 基礎学習 → 会話 SFT → 項目読解 → 計算・カードの振り分け → 実機会話テスト → 強化学習

1.3 全体の構成

最終的な Bot は、3 つのモデルと 1 つの検索からなる (図1)。ルーターと答え役は、現行の Mia をコピーして微調整した**別のモデル**である。現行の Mia は、会話と、項目を読んで答える役を兼ねる。

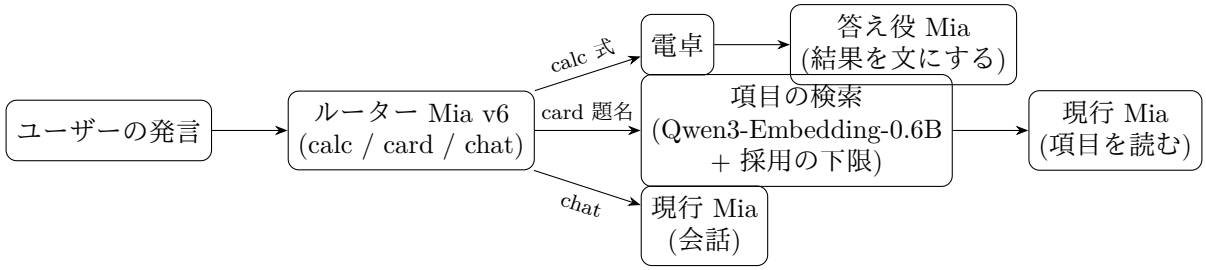


図 1: Bot の構成。ルーターが 3 つの経路に振り分ける。

2 語彙・学年・文脈長の調査 (10 月 23 日)

2.1 語彙

トークンではなく見出し語 (活用をまとめた数、WordNet と頻度で簡易に判定) で数えた。現在のトークナイザーは 15,946 トークンで、うち単語として実在する 13,206 トークンが、見出し語 7,899 語にあたる。語彙を「約 15,900」と言うより、人間の数え方では約 7,900 語を 1 トークンで持っている。

学習データで実際に使われる語は、会話データ (Qwen 生成 30 万会話、延べ 1,304 万語) で見出し語 9,958 語、TinyStories(先頭 2,000 万トークン) で 9,325 語であった。使用頻度は偏っており、会話データでは上位 500 語が延べの 88.7%、上位 2,000 語が 98.6% を占める。**延べ語数の 99.6% は、すでに 1 トークンで持っている語**で、持たない語は見出し語で約 4,200 あるが、延べでは 0.4%(名前、擬音など) である。この結果から、語彙は増やさない (増やしても得るものが小さい) と決めた。

2.2 学年の目安

物差しには Dale-Chall(新版 2,884 語、小学 4 年生の 8 割が知っている語)[5] を使った。会話データの延べ語数の 94.1% が Dale-Chall に入り、TinyStories は 90.5% である。見出し語の数では 25% にとどまるが、残りは固有名詞とまれな語で、延べでは数% にすぎない。使われる語の中心は、**小学校低〜中学年 (2〜4 年生)** の語彙と推定する。年齢別習得表 (Kuperman など) は入手できず、学年は Dale-Chall と頻度からの推定である。

2.3 文脈長

当時の文脈長 (block_size) は 256 トークンで、会話データの平均は 54 トークン、最長 246 トークン (最長 4 往復) であった。実測では、1 発言が平均 16.3 トークン、1 往復 41、4 往復 110 で、1,024 トークンを会話で埋めるには約 30 往復が要る。文脈長を変えて増えるパラメータは位置埋め込みだけで、256 から 1,024 では約 0.4M(全体の約 1%) である。ただし位置埋め込みを広げるため、基礎学習のやり直しが必要になる。オーナーの希望により、文脈長を **1,024** にすることを決めた。

3 データの作成

3.1 長い会話 (Qwen)

1,024 トークンに合う長い会話は公開データにほとんどなく (10 往復以上のものは見つからなかった)、Qwen3.8-27B(INT4) を手元の GPU(RTX 4090) で vLLM により動かして作った。API 費用はかからず、時間と電気代だけである。試作 (10 往復と 30 往復を各 100 会話) では、Qwen は往復数を数えられず頼んだ数より少なく書く (30 往復を頼んで平均 27 往復) こと、話がよく脱線することが分かった。小学 4 年生の語の割合は 92.5%(既存データは 94.1%) であった。

本番生成は、10 往復・20 往復・30 往復を 3:2:1 の割合で、約 13 時間 49 分かけて行った (表1)。

表 1: 長い会話の生成結果 (合計 54,525 会話、2,206 万トークン)

頼んだ往復数	会話数	総トークン (万)	実際の往復 (平均)	1 会話の平均トークン
10 往復	29,141	803	8.3	275
20 往復	17,912	888	17.6	496
30 往復	7,472	515	26.5	689

不採用は約 4.9 万件で、読めない形式 3,694、ターン数が奇数 3,575、1,024 超え 801、評価の固定問題との重複 131 などである。サンプルを読んだ範囲では、話は最後まで続き語彙もやさしいが、Mia の返事が毎回「共感 + 質問」に偏る傾向があった。

3.2 基礎学習用のお話

基礎学習には、TinyStories[1](約 5.49 億トークン) に加え、SimpleStories[2](MIT、211.6 万本、6.29 億トークン) を使うことにした。SimpleStories の調査 (2 万本の無作為抽出) では、平均 310 トークン、最長 900、1,024 超は 0 本で、小学 4 年生の語の割合は延べ 89.2%、「Once upon a time」を含む話は 0.6% であった (論文は TinyStories で 59% と指摘)。合計約 11.8 億トークンである。

4 基礎学習 (文脈長 1,024)

モデルは 10 層・8 ヘッド・512 次元 (40.17M) で、単語埋め込みは Qwen3-Embedding[4] を主成分分析で 512 次元にしたものを固定する。事前学習の量は、約 20 トークン/パラメータという目安 [3] を下限の参考にし、実際は約 35 億トークン (約 88 トークン/パラメータ、3 エポック) を学習した。データの重複なしの量 (11.8 億トークン) でも約 29 である。

学習は、各エポックで 485 万話をシャッフルし、1 話を 1 行 (`<bos>` から `<eos>`) として話をまたがず、長さの近い話をそろえてバッチにする。3 エポック (120,789 ステップ、約 35 億トークン)、lr 10^{-3}、cosine である。最初の試行では、話が最長で約 950 トークンのため、全ての話を位置 0 から始めると 700〜1,023 番の位置埋め込みがほとんど学習されない見込みであった (実測ではなく見込みである)。そこでオーナーの提案により、**50% の話を位置 0 から、残り 50% を** 0〜1024−**(話の長さ) の乱数の位置から**始めるやり直しを行った。検証損失を「位置 0 から」[start] と「1,024 の末尾にそろえる」[end] の両方で測ると、差は 0.004 以下で、後ろの位置も同じ精度で学習できた (表2)。

表 2: 基礎学習の最終の検証損失 (step 120,000、各 3,000 話)

データ	[start]	[end]
TinyStories	1.0981	1.1022
SimpleStories	1.5099	1.5133

予定の 120,789 ステップのうち約 700 ステップ (0.6%) を残して、実装のバグ (エポックごとの捨てるバッチ数が変わる) で停止した。学習率は 116,000 以降下限で損失も横ばいだったため、実害は小さいと判断し、step 120,000 のチェックポイントを使った。所要は約 3 時間である。

5 会話 SFT

短い会話 326,115 と長い会話 53,406 の合計 379,521 会話 (3,794 万トークン、損失の対象 2,123 万) で教師あり微調整を行った。3 エポック、lr 3×10^{-4}、埋め込み固定、文脈長 1,024 で、約 9 分 22 秒である。検証損失は開始前 3.9424 から 1.6415(短い 1.6285、長い 1.6472) になった。5 エポックにすると、エポック 4 から 5 で短い会話の検証損失が上がり (1.6502 から 1.6788)、過学習の兆しが出たため、3 エポックで足りると判断した。

オーナーの試し会話 (約 400 トークン) では、AI であることを正直に言う、滑り台やニューヨークの話題が自然、という利点があった。一方、綴り間違いによる取り違え、同じ会話内の矛盾 (「My cat is named Coco」と言った直後に猫の名前を聞くと「I do not know your cat's name」と答えた。3 エポック版と 5 エポック版の両方)、代名詞の取り違え (「My son lives there」に「He is a famous place.」)、意味の通らない文が見られた。400 トークンで起きているため、文脈の長さではなく、モデルの理解力とデータの偏りが原因と見ている。

6 項目 (カード) による読解

6.1 項目の設計

カードは短文では情報が足りないとのオーナーの指摘を受け、**題名 +200〜500 トークンの説明文 + 質問**の「項目」にした。小学校低学年 (1〜2 年) がわかる言葉で、1 文 12 語以内とする。質問は 1 項目 20 問 (wh 9、yes 2、no 2、count 3、unk 4) で、unk は本文に書かれていないことを聞き、答えは必ず `I do not know.` である。

題材は、12 のテーマ (動物・昆虫・植物・地球・天気・宇宙・からだ・食べ物・乗り物・家・学校と仕事・遊び) ごとに Qwen に挙げさせ、語彙の条件と Qwen の判定で整えて 1,155 題材とし、観点を増やして 1,076 題材を追加し、合計 2,231 題材とした。

本文と質問の作り方は 2 つ試した。Qwen が書いた本文を DeepSeek が事実確認する方法は、間違いの見逃しと新しい誤りがあり使えなかった。採用したのは、**DeepSeek が本文と質問 20 問を 1 回で直接作り、Qwen が各質問と答えを検証する**方法である (失敗は 3 回までやり直し)。結果は 2,226 項目 (約 4.4 万問)、DeepSeek 費用は約 $4.95(見積もり) であった。Qwen の検証の ok 率は、最初の 1,151 項目で 95.9% であった。

6.2 語彙の追加

読解データにだけ出る割れる語 (基礎データと会話データに片の並びが一度も出ない語) は 751 語あった。出現 5 回以上などで絞った 145 語 (nougat, bonsai, caribou など) と中間の断片 121 個を足し、語彙を 15,946 から **16,212** にした (新語彙 ts_v4)。基礎モデルは学習し直さず、新語の埋め込みは旧語と同じ手順で計算し、旧語の再計算が保存値と一致する (cos 1.0) ことを確認してから行を足した。語彙を増やさない方針の例外であり、オーナーが「読解にだけ出る語なら基礎からやり直さなくてよい」と提案した。

6.3 読解 SFT と基準テストの確定

会話 SFT 済みのモデルから読解 SFT を行った。1 項目につき質問 5 問の多ターン会話を複数サンプルとし、会話の復習を混ぜた。質問は、同じ項目の本文に対して DeepSeek が既存の質問と重ならない新しい質問を作り (39,934 問、費用の見積もり約 $3.85)、no の弱さに合わせて配分を変えて倍にした (第 5 版)。

評価は、学習に使わない 50 項目の全 931 問を貪欲生成で答えさせた、自動判定の正解率である。unk は答えが `I do not know.` と完全一致、他の型は模範解答の内容語 (3 文字以上) の 6 割以上が答えに出ていて、かつ `I do not know.` でないこと (yes/no は先頭語も一致) を条件にする。判定は内容語の一致なので、人が見るより甘い。

表 3: 読解 SFT の推移 (読解テスト 931 問の正解率% と会話テスト)

モデル	wh	yes	no	count	unk	全体	会話
会話 SFT のみ	-	-	-	-	-	7	85.0
読解第 1 回 (旧語彙、1,151 項目)	62	70	57	70	86	68	-
読解第 3 回 (2,226 項目)	71	87	54	82	83	75	84.1
読解第 5 版 (質問を倍、確定)	78	76	71	81	90	**80**	**84.6**

第 5 版は、wh・no・unk が大きく改善した一方、yes は 87 から 76 に下がった (追加の質問が no に偏った影響の可能性)。会話の検証損失は 1.64 から 1.79 に悪化したが、会話テストの点は保たれた。2026 年 10 月 26 日に、この第 5 版を**現行モデル**として確定した。

7 会話テスト

オーナーの提案により、5 回のやりとりに点をつけるテストを作った。会話 SFT の検証会話から、短い 50 本と長い 50 本 (最初の 5 発言) を選んで凍結し、ユーザー発言を固定して Mia に貪欲生成で答えさせる。DeepSeek が 1 回 20 点 (答える 8・覚えている 6・ことば 4・きれいさ 2) で採点し、1 回の平均 ×5 を 100 点満点とする。基準は**標準的な小学校低学年 (7 歳) の子どもが約 90 点** (1 回 18 点) で、質問を無視した返事は最大 10 点、矛盾・取り違えは最大 12 点、不適切な助言は最大 8 点とする。最初の基準では 89.0 点と甘すぎたため、2 回直して厳しくした。採点者は甘めの傾向があるので、絶対値より比較に使う。結果は、会話 SFT のみ 85.0 点、読解 SFT 後 (確定)84.6 点である。

以後、読解テスト (約 1 分、費用なし) と会話テスト (約 2 分、約 $0.07) を**基準テスト**とし、問題と採点基準は変えず、変えるときは旧版と並べて記録する決まりにした。

8 計算の振り分け: ルーター Mia(Plan B)

8.1 課題と方針

従来の計算は、ルーターの頭が計算と判断したら正規表現で式を取り出す一方通行で、文章題から式を作れず、返事も固定文であった。また、答える側の Mia は電卓の結果を読めない (`Facts: 12 - 1 = 11` を渡して正解 5%)。

判断と答えを同じモデルにやらせる案 (Plan A) は、小さなモデルへの負担と会話の劣化が心配であった。そこで、オーナーの提案により **Plan B**、すなわち現行 Mia を微調整した**別のルーター Mia**(判断と式づくり) と、別に学習した**答え役 Mia**(結果を自然な文にする) の構成にした。ルーターの出力は特殊トークンなしの平文で、`calc 2 + 3`、`card 題名`、`chat` である。

8.2 データ

文章題を 14 の型 (増える、演算語なし、のこり、差、かけ算、わり算、2 段、関係ない数字入り、3 項、おつり、年上年下、半分 2 倍、式だけ、続きの質問) で、テンプレートから作った。大きい数 (最大約 3,000) を 3 割にした。式と答えは電卓で検算する。言い換えは Qwen が 3 通り作り、**数の集まりが元と同じで、Qwen が独立に解いて元の答えと一致するものだけ**を採用した (最初は関係ない数字が足し算に混ざる言い換えがあり、この検査で落とした)。数字を含むが計算ではない発言 (「I am 7 years old.」) も、chat の否定例として加えた。

8.3 経過と結果

表 4: ルーターの経過 (計算: 判断/式/答え、会話: 誤呼び出し率)

版	計算 (判断/式/答え)	会話の誤呼び出し
v1(単発の問題だけ)	1.000 / 0.968 / 0.987(旧テスト)	0
v2(型と大きい数を追加)	0.978 / 0.627 / 0.662(履歴つきテスト)	0.026
v3(履歴に前の計算・会話)	**1.000 / 0.943 / 0.986**	**0**

v1 は凍結テストで高く出たが、手書き 20 問で「2 plus 3」や 3 項、4 桁の数が崩れることが分かった。型を足した v2 は、会話の途中で履歴に前の計算があると前の問題の数字を混ぜる欠陥が出た。v3 は、履歴に前の計算や会話をつけて学習し、解消した。

答え側は、現行 Mia を別コピーで微調整した `answer_mia_v1` が答えの正しさ 0.991(800 件)、固定文に落ちる率 0.005 であった。現行 Mia に復習 4 万件を混ぜて 1 つにまとめる案 (`answer_mix_v1`) は、答え 0.981、読解 79%、会話 83.1 と、少し下がった。オーナーは、当面は別コピーのまま保持すると決めた。

9 カードへの拡張

9.1 ルーターへの追加

ルーターの出力に `card 題名`を足し、事実の質問を項目の検索に回す。学習データは、項目の質問のうち題名を含むもの (12,224)、「Tell me about X」型 (4,152)、代名詞の質問 (2,177)、題名を含むが事実を聞かない発言 (chat へ、3,869)、前の話題を引きずらない切り替え (2,443)、項目にない話題の質問 (3,010) などである。評価用に 150 題名 (読解テストの 50 項目と無作為 100) を学習から外した。

9.2 検索と採用の下限

検索は、項目の本文を Qwen3-Embedding-0.6B[4] で埋め込み、質問との近さに、ルーターが出した題名の手がかりを小さく加える。採用は 2 段の下限で決める。質問との類似度が上の下限 (0.70) 以上なら採用し、下の下限 (0.50) 以上で上の下限未満のときは、ルーターが出した話題の語が項目の本文に出る場合だけ採用する。どちらでもなければ「項目なし」とし、`I do not know.` と答える。Mia の単語埋め込み (`wte`) の平均で検索する案も試したが、正しい項目を 1 位に引けた率が 62%(語の重みなしでは 27%) で、同じ条件 (下限なし、1 位) の Qwen3-Embedding の 77.3% に及ばなかった。

9.3 全体テストと下限の選択

読解テストの 50 項目 931 問を、ルーター、検索、現行 Mia の読解の順に通した (題名はルーターの学習に使っていない)。項目を最初から渡した場合は 80% である。

表 5: カードの全体テスト (931 問) と、項目にない話題 215 問での `I do not know.` の率

構成	全体の正解率	項目を引けた率	項目なしの `I do not know.`
項目を最初から渡す (参考)	80.0%	-	-
題名索引のみ	70.0%	67.6%	-
埋め込み検索 (上位 1 枚、下限なし)	74.8%	77.3%	-
上位 3 枚を順に読む	73.6%	77.3%	-
下限 0.40/0.60	73.6%	76.0%	57.7%
下限 0.50/0.70(採用)	**70.8%**	72.7%	**67.0%**
下限 0.60/0.80	63.8%	63.4%	83.3%

下限を上げると、作り話は減るが、正しい項目の質問も捨てられる (取りこぼしと作り話の交換)。オーナーは、バランスのよい 0.50/0.70 を採用した。上位 3 枚を順に読む方式は、別の項目から答えを作って unk の正解率を落とす (89% から 79%) ため採用しなかった。外れの主因は、質問が題名でなく部分の名前だけを言う場合 (corn の項目の「What covers the cob?」) と、項目の重なり (honeydew と aphid) である。

9.4 ルーター v6: 実機の弱点を直す

オーナーの実機テストで、雑談が続くと整った質問でもカードを引かない、「You know what is Sun?」「Tell me more about Moon」などのくだけた言い方や、「grass hopper」のような分けた題名を引かない、という弱点が見つかった。項目はすべてあったので、原因はルーターにあった。雑談の履歴つきの事実の質問 (7,000)、くだけた言い方 (6,228)、同じ話題の好みの後の質問 (1,500)、好み・気持ちの chat(6,500)、分けた題名 (506) をテンプレートで足し (21,734 件)、v6 を作った (表6)。

表 6: ルーター v5 と v6

テスト	v5	v6
新テスト (学習と別の言い方・別の題名) のカード判断	0.610	**0.923**
新テストの題名一致	0.488	0.778
凍結テストのカード判断	0.995	0.993
凍結テストの計算の答え	0.977	0.976
会話の誤呼び出し率	0.0013	0.0003
全体テスト (下限 0.50/0.70)	70.8%	70.4%
項目なし話題の `I do not know.`	67.0%	65.6%

新しい弱点だけが大きく伸び、凍結テストと計算はほぼ維持された。全体テストはわずかに下がり (70.8 から 70.4%、項目なしの断りは 67.0 から 65.6%)、これは誤差程度とみている。実機でうまくいかなかった発話は、すべて項目を引くようになり、「You like Moon?」は意図どおり chat のままであった。

ただし、新テスト (0.610 から 0.923) は学習と同じテンプレート生成器 (言い回しと題名だけを分けたもの) で作っており、同じ分布での改善である。また、実機会話テストの 6 場面は v6 を作る動機になったオーナーの実機ログで、学習用の言い回しもその失敗例を模している。テストの場面そのものは学習に使っていないが、場面の型は開発の標的であった。

10 実機会話テスト

10.1 テストの設計

基準テストでは測れない不自然さ (広い依頼への答え、代名詞の続き、雑談からカードへの出入り、文の崩れ、事実の間違い) を測るため、オーナーの指示で 5 つ目の基準テストを作った。ボット全体を通す固定の複数ターンの場面 24 個 (計 120 発言) で、オーナーの実機ログ 6 場面のほか、計算、カード、雑談、記憶、崩れた英語、話題の切り替えを含む。ユーザー発言は固定で、場面ごとに乱数を固定する。DeepSeek が会話テストと同じ 20 点式で採点し、基準は 7 歳の子どもで約 90 点、**合格ラインは 80 点**とする。事実や数の間違いは最大 8 点に抑える。学習の報酬や学習データには使わない決まりにした。

10.2 結果

現行の構成 (ルーター v6、現行 Mia、答え役、下限 0.50/0.70) の点は **77.9〜78.2 点**で、合格ラインに届かなかった。2 回の測定は、77.9 が 120 発言、78.2 が 110 発言 (1 場面を採点できなかった) の平均である。2 回はボットの返事が同じ 110 発言で、採点だけが 0.3 点違い、これが採点の再現性の目安になる。以下の内訳は 77.9 の回の値で、120 発言のうち 80 点以上は

87、60 点未満は 26、間違い・作り話は 15 であった。場面別では、記憶・雑談・大きい数の計算・天気・話題の切り替えが 90 点で、項目にない話題 (55 点)、面積 (62 点)、お金の続きの計算 (65 点)、accordion(66 点) が低かった。

表 7: 実機会話テストで 80 点未満だった発言 (現行構成、経路別)

経路	80 点未満	発言数
会話	7	63
カード	**22**	42
計算	4	15

失点の半分以上がカードの経路にある。原因は、(1) 項目にない話題で似た項目から作り話をする (「What is a bridge?」に、road の項目から「A bridge is a long hole in the ground.」)、(2) 広い依頼で読む役が外す (「Tell me about Mars.」に「The moon is a planet.」、「Is Mars a moon?」に「Yes」)、(3) 代名詞の続き (「tell me more about it」) で検索が項目を選ばない、(4) 計算の型の不足 (面積が `5 + 2` になる、お金の続きで前の残りを使わない)、である。

11 強化学習の試み

実機会話は「正解がなく、揺らぎの中から良いものへ誘導したい」とのオーナーの考えから、強化学習 (GRPO 型 [6]) を試した。現行 Mia の別コピーを方策とし、新しく作った場面 (実機会話テストと別の題材) の途中まで進めて、同じ状況の返事を 8 本サンプルする。DeepSeek が 8 本を実機会話テストと同じ 20 点式で採点し (カードの回は項目の本文を、事実の誤りの確認に使う)、群内で標準化した報酬を利得にして方策勾配を 1 回更新する。元のモデルとの KL の制限も加えた。1 ステップは 8 場面で、100 ステップの費用は DeepSeek の使用量の見積もりで約 $1.0、約 14 分である。訓練中の報酬は、温度 1.0 のサンプルを別の採点プロンプト (項目の本文つき) で採点した値で、実機会話テストの点とは設定が違うため、数値を直接比べない。

表 8: 強化学習の 2 回の結果 (100 ステップ)。すべて単一の乱数の種

モデル	実機会話テスト	読解テスト	訓練中の報酬 (20 点満点)
現行 Mia	77.9	80%	-
第 1 回 50 ステップ (復習なし、$\beta = 0.02$)	77.6*	76%	11.7→13.7
第 1 回 100 ステップ	79.0	**71%**	(同上)
第 2 回 50 ステップ (復習 $+\beta = 0.1$)	78.0	78%	11.7→12.3†
第 2 回 100 ステップ	78.4*	77%	(同上)

*1 場面を採点できず 110 発言の平均。共通の 110 発言で比べ直すと、現行 Mia 77.86、第 1 回 50 77.59、第 1 回 100 78.41、第 2 回 50 77.45、第 2 回 100 78.36 で、差は -0.4〜$+0.6$ 点。† 最初の 20 ステップの平均から最後の 10 ステップの平均。途中の 10 ステップ移動平均の最大は 13.4。第 1 回は最初と最後の各 20 ステップの平均。

訓練中の報酬は上がったが、実機会話テストの差 (最大 +1.1 点、共通の発言で比べると -0.4〜$+0.6$ 点) は誤差の範囲である。読解は、復習なしでは 71%、復習を混ぜても 77〜78% に下がり、特に no の質問が弱くなった (71% から 51〜58%)。基準を保てないため、**2 回とも採用しなかった**。会話の経路は失点が少なく、失点の主因が返事の文ではなく、ルーター・検索・計算の型にあるため、返事を強化する学習では伸びにくかったと考える。

12 考察

12.1 うまくいったこと

- **項目への作り直し**。カードを辞典のような項目にして読解を学習し、項目の作り直しに質問の倍増と語彙の追加を含む一連の改良で、読解は 68% から 80% になった (第 1 回は旧語彙・1,151 項目、第 5 版は質問倍増で条件が複数違い、1 行カードとの同一条件の比較は

していない)。なお、オーナーの試用では、基盤の Mia が項目の内容をかなり覚え、カードなしでも答えることがあるという印象であったが、これは本報告では測定していない (測るなら、読解テストの 50 項目の題名だけを聞く、などの評価が要る)。
- **ルーターの別モデル化**。判断と式づくりを別モデルにしたことで、現行 Mia の読解 80% と会話 84.6 点を保ったまま、計算の答え 0.976〜0.977(版・テストにより異なる) を得た。
- **検査つきの合成データ**。言い換えを独立に解かせて答えを確かめる、数の集まりが同じかを確かめる、という検査で、意味が変わったデータを除けた。
- **実機で見つけて直す循環**。基準テストは決めた範囲の後退を見つけるのに強く、実機の試用は範囲の外の弱点を見つける。両方を使うことで、ルーター v6 の弱点を見つけて直せた。

12.2 限界と注意

- すべての結果は**単一の乱数の種**の値で、実機会話テストの数点の差は誤差である (120 発言)。同じ返事の再採点でも約 0.3 点違った。会話テストの差 (85.0、84.6、84.1) も同程度で、「保たれた」とは言えても「改善した」とは言えない。
- 文脈長 1,024 の効果は、256 との比較や語彙据え置きとの切り分けでは測っていない。Bot は、ルーターも会話も直近 3 往復 (約 80〜110 トークン) しか渡しておらず、カードの経路は質問だけで読む。会話テストも最初の 5 発言までで、長い会話の一貫性の評価は未実施である。代名詞の続きに弱いこととも関係すると考える。
- 会話テストと実機会話テストの採点は **LLM(DeepSeek)** で、甘めの傾向があり、絶対値は比較用である。読解の自動判定は内容語の一致なので、文が崩れていても正解になりうる。
- 評価の 50 項目などは開発中の選択 (エポック数、下限など) にも使っており、**選択の偏り**を含む。ルーターの凍結テストは、学習と同じ生成器 (テンプレート +Qwen 言い換え、別シード) で作ったため、実際の言い回しより易しい。
- 項目の内容は DeepSeek が作り、Qwen が検証したもので、事実の誤りが残る (「No, a tomato is not a fruit.」は項目の記述どおりだが、正しくは果物である)。
- 答え役の訓練データは、検査器のカンマ入りの数の不具合で、1,000 以上の答えの文が生成側で全部落ちていた (直したが再生成は未実施)。答えテスト 0.991 は、1,000 以上の答えの訓練が薄いままの値である。前提のない質問 (「7+7 と計算」)、訂正、複数の事実をまたぐ計算も未対応である。
- DeepSeek の費用は、プログラムが使用量から見積もった値である (項目 $4.95、質問追加 $3.85、会話テスト約 $0.07/回、実機会話テスト約 $0.03/回、強化学習約 $1.0/回)。
- ライセンスは 2026 年 10 月 28 日に Hugging Face のカードと規約で確認した。TinyStories は CDLA-Sharing-1.0(データを再配布する場合のみ同じ条件が付き、学習したモデルの公開は妨げない)、SimpleStories は MIT、Qwen3-Embedding は Apache-2.0、DeepSeek の API 規約は出力を他のモデルの学習に使うことを認めている。会話データの生成に使った Qwen(RedHatAI/Qwen3.8-27B-INT4) も Apache-2.0 で、カードに出力の利用制限の記載はない。以上は規約の読み取りであり、法的な助言ではない。

13 まとめと今後

MIA2 では、基礎学習用の語彙は据え置いて (読解にだけ出る語を後から足し 16,212 語) 文脈長を 1,024 にし、基礎学習・会話 SFT・項目読解を作り直した。計算とカードへの切り替えは、現行 Mia を変えずに、別のルーターで実現した。現在の Bot は、会話はスムーズに受け答えでき、計算は文章題から式を取り出して電卓で答え、事実の質問は項目を引いて読んで答える。5 つの基準テストの値は、読解 80%、会話 84.6 点、計算の答え 0.976(ルーター v6、凍結テスト)、カードの全体 70.4%(項目にない話題の断り 65.6%)、実機会話 77.9 点 (合格ライン 80) である。

未実施の案は次のとおりである。

1. ルーターが出した題名が項目の題名と完全に一致するなら、下限を通さず採用する (代名詞の続きの対策、学習不要)。
2. 読解側の追加学習 (別コピー)。広い依頼、「Do you know…」、本文にない関係の yes/no を断る例を足す。

3. ルーター v7。前の計算結果を使う型、面積などの掛け算の型を足す。
4. 部分の名前の索引。

強化学習は、失点の原因が減ってから、もう一度試す価値がある。

参考文献

[1] R. Eldan and Y. Li, "TinyStories: How Small Can Language Models Be and Still Speak Coherent English?" arXiv:2305.07759, 2023.

[2] L. Finke, C. Sreedhara, T. Dooms, M. Allen, E. Zhang, J. D. Rodriguez, N. Nabeshima, T. Marshall, and D. Braun, "Parameterized Synthetic Text Generation with SimpleStories," arXiv:2504.09184, 2025. データ: Hugging Face `SimpleStories/SimpleStories`.

[3] J. Hoffmann et al., "Training Compute-Optimal Large Language Models," arXiv:2203.15556, 2022.

[4] Y. Zhang et al., "Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models," arXiv:2506.05176, 2025.

[5] J. S. Chall and E. Dale, *Readability Revisited: The New Dale-Chall Readability Formula*, Brookline Books, 1995.

[6] Z. Shao et al., "DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models," arXiv:2402.03300, 2024.